

AI & Machine Learning

Week 2: Case Studies Portfolio

Анализ качества воздуха, NLP и выявление мошенничества

Команда: Абзал, Амир, Диас, Темирхан & Медет

Обзор Проекта

Мы выполнили 4 прикладные задачи, покрывающие полный цикл Data Science:

- **Task 1:** Экология — Exploratory Data Analysis (EDA) для г. Павлодар
- **Task 2:** Прогнозирование — Machine Learning для предсказания выбросов
- **Task 3:** Обработка текста — NLP Pipeline для анализа тональности
- **Task 4:** Финансовая безопасность — Работа с Imbalanced Data

Task 1: Качество воздуха в Павлодаре

Цель: Оценить исторический уровень загрязнения воздуха.

- Оптимизация данных: из 3 ГБ сырых данных отфильтрованы только CSV файлы Павлодара (PM2.5, NO2, SO2).
- Временные ряды (Time-series) сгруппированы по дням.
- Выявлены сезонные пики в период отопительного сезона.
- Рассчитаны дни превышения нормативов ВОЗ ($15 \mu\text{g}/\text{m}^3$).

Task 2: ML-Прогнозирование выбросов

Цель: Создать модель предсказания уровня PM2.5 на следующий день.

- Модель: Linear Regression (Линейная регрессия).
- Инженерия признаков (Feature Engineering): использование "лагов" — исторического загрязнения за предыдущие 1-2 дня.
- Модель способна заранее предупреждать о "грязных" днях, что критично для жителей промышленных городов.

Task 3: NLP Анализ тональности

Цель: Автоматическая классификация текстов (Позитив / Негатив).

- Набор данных: Открытый датасет Movie Reviews (NLTK).
- Предобработка: векторизация текста с помощью TF-IDF.
- Алгоритм: Naive Bayes (MultinomialNB).
- Результат: Высокая точность, применимость архитектуры для анализа отзывов на приложения банков и E-commerce.

Task 4: Выявление мошенничества

Цель: Поиск фрода в банковских транзакциях.

- Проблема: Жесткий дисбаланс данных (99% легальных транзакций, 1% мошенников).
- Решение: Использование алгоритма Random Forest с автоматической балансировкой весов (`class_weight='balanced'`).
- Метрики: Фокус смещен с общей точности (Accuracy) на матрицу ошибок (Confusion Matrix) для минимизации ложных блокировок легальных клиентов.

Заключение

- Успешно применены методы EDA, Регрессии, NLP и классификации ансамблями.
- Проект оптимизирован: размер директории сокращен в десятки раз.
- Код повністю изолирован в виртуальной среде (venv) и готов к воспроизведению.

Спасибо за внимание!